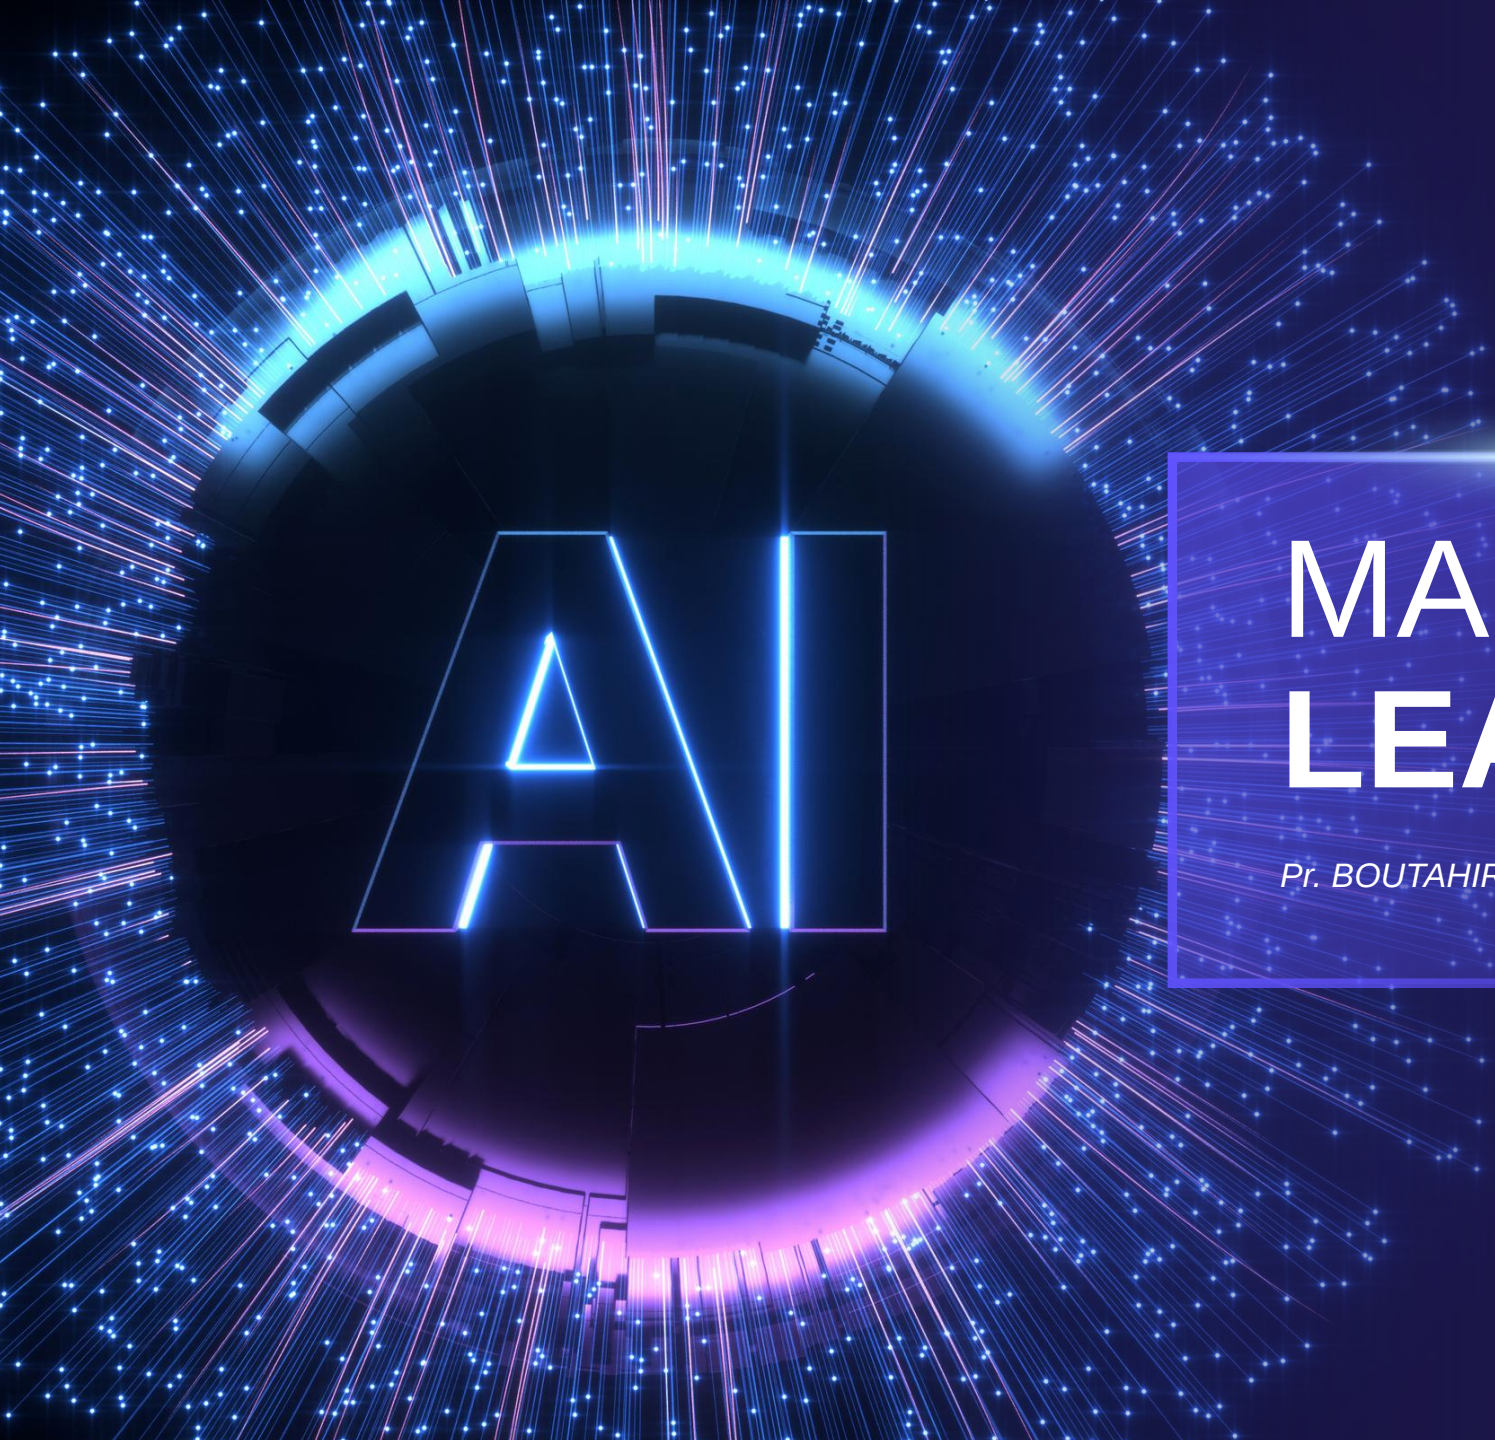

المدرسة الوطنية للذكاء الاصطناعي والرقمنة - بركان
ÉCOLE NATIONALE DE L'INTELLIGENCE ARTIFICIELLE ET DU DIGITAL - BERKANE

MACHINE **LEARNING**

Pr. BOUTAHIR Mohamed Khalifa

Année universitaire : 2025 / 2026

Chapitre 4:

Apprentissage non supervisé

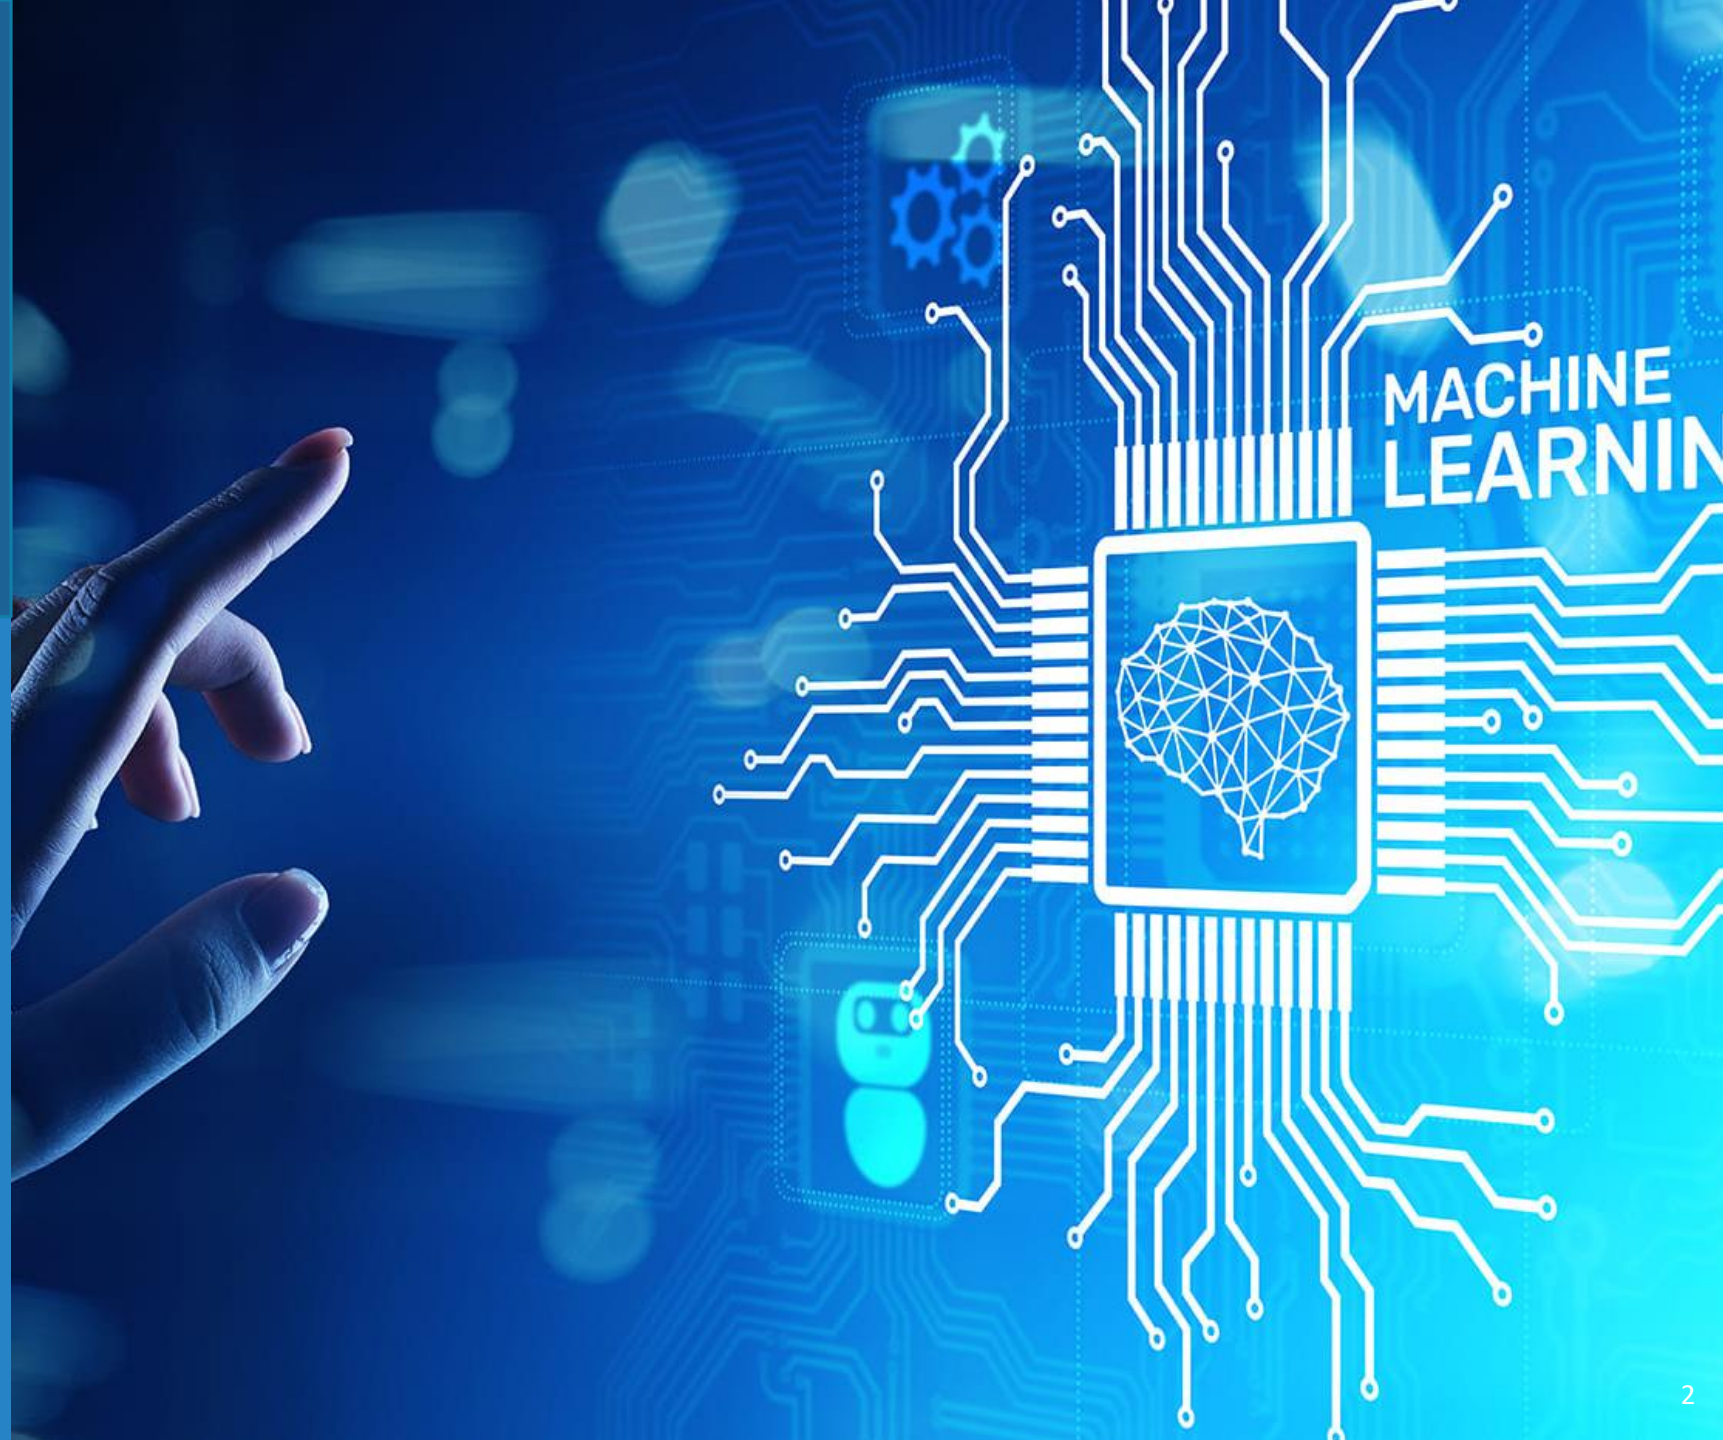

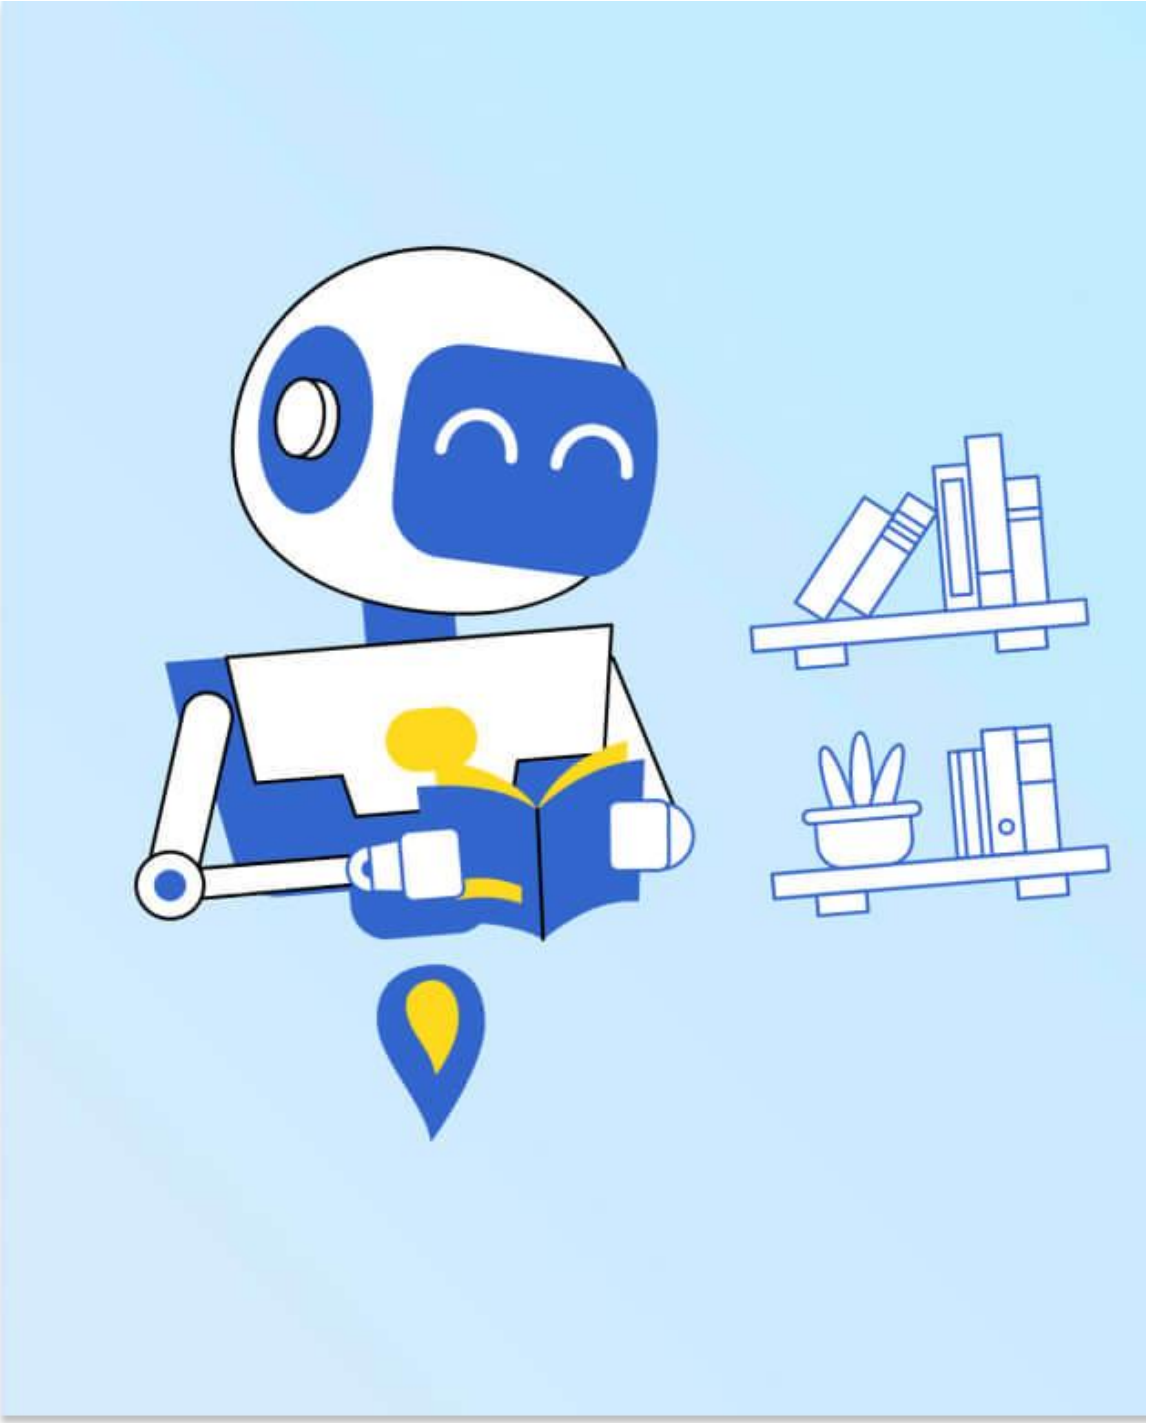

CHAPITRE 4 — Apprentissage non supervisé

1. Introduction et changement de paradigme.
2. Les trois branches de l'Apprentissage Non Supervisé.
3. Branche 1 : Clustering.
4. Branche 2 : Réduction de Dimensionnalité.
5. Branche 3 : Détection d'Anomalies.

Introduction

Le Changement de Paradigme

- Hier (Supervisé) : Le modèle est entraîné sur des données étiquetées (Entrée-Sortie) avec l'objectif de prédire une valeur ou une catégorie précise.
- Aujourd'hui (Non Supervisé) : Données BRUTES (Entrée seule). L'algorithme a pour objectif d'extraire les schémas et motifs cachés de manière autonome.

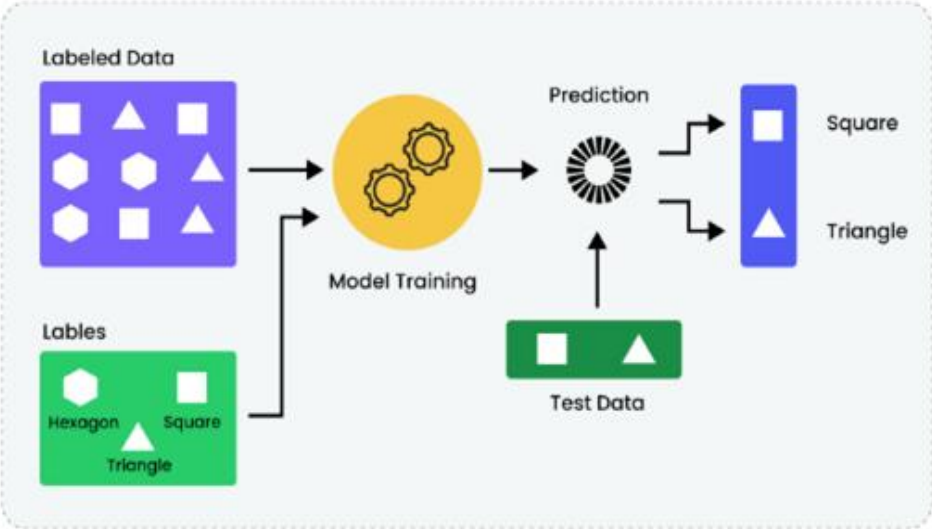

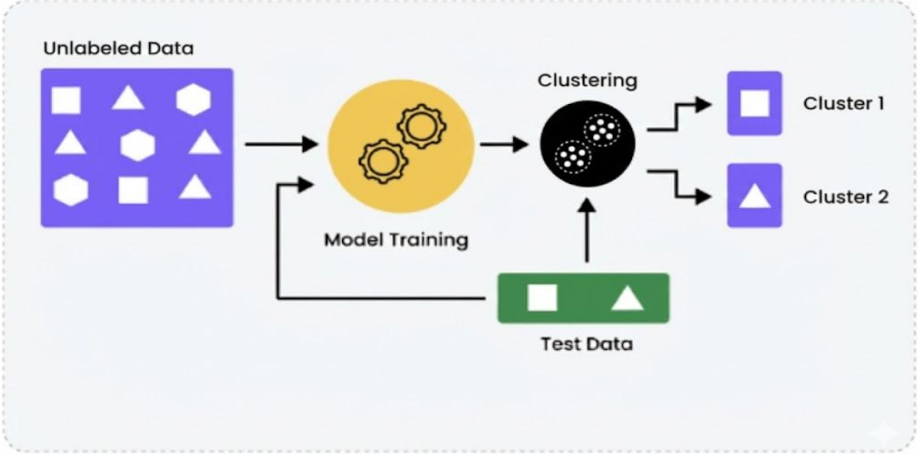

Introduction

Qu'est-ce que l'Apprentissage Non Supervisé ?

C'est une branche de l'IA où l'algorithme apprend des modèles à partir de données sans étiquettes.

Analogie : Imaginez un enfant qui trie des pièces de lego par forme et couleur, sans que personne ne lui ait appris les noms "rouge" ou "brique".

- Découverte de structures cachées.
- Aucun feedback direct (pas de correction d'erreur explicite).
- Exploration autonome des données.

Introduction

Comparaison : Supervisé vs Non Supervisé

Critère	Apprentissage Supervisé	Apprentissage Non Supervisé
Données d'entrée	Étiquetées (Input X, Output Y)	Non Étiquetées (Input X seulement)
Objectif	Prédire ou Classer	Découvrir, Regrouper, Simplifier
Feedback	Direct (Correction d'erreur)	Aucun (Interprétation humaine)
Exemple	Détection de Spam (Spam/Non-Spam)	Segmentation Client (Groupes d'achats)

Introduction

Comparaison : Supervisé vs Non Supervisé

Critère	Apprentissage Supervisé	Apprentissage Non Supervisé
Données d'entrée	Étiquetées (Input X, Output Y)	Non Étiquetées (Input X seulement)
Objectif	Prédire ou Classer	Découvrir, Regrouper, Simplifier
Feedback	Direct (Correction d'erreur)	Aucun (Interprétation humaine)
Exemple	Détection de Spam (Spam/Non-Spam)	Segmentation Client (Groupes d'achats)

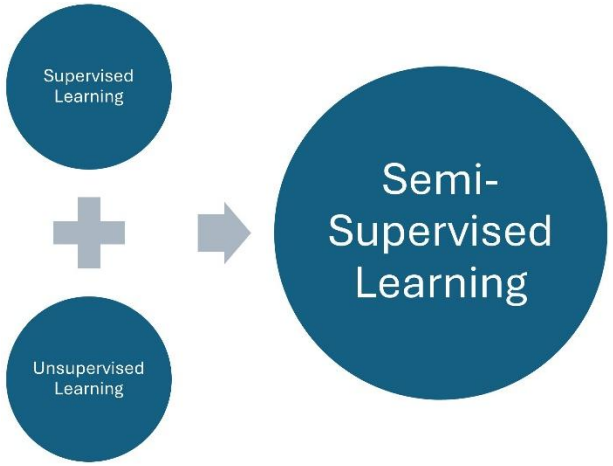

La question est : comment l'apprentissage semi-supervisé fonctionne-t-il ?

Introduction

Pourquoi l'Apprentissage Non Supervisé ?

1. Coût de l'Étiquetage

Annoter manuellement des millions d'images ou de textes est extrêmement coûteux et prend un temps considérable.

2. L'Inconnu

Parfois, nous ne connaissons pas les catégories à l'avance (ex: découverte de nouveaux types de virus ou d'attaques).

3. Préparation

Il permet de nettoyer et simplifier les données complexes avant de les utiliser dans des modèles supervisés.

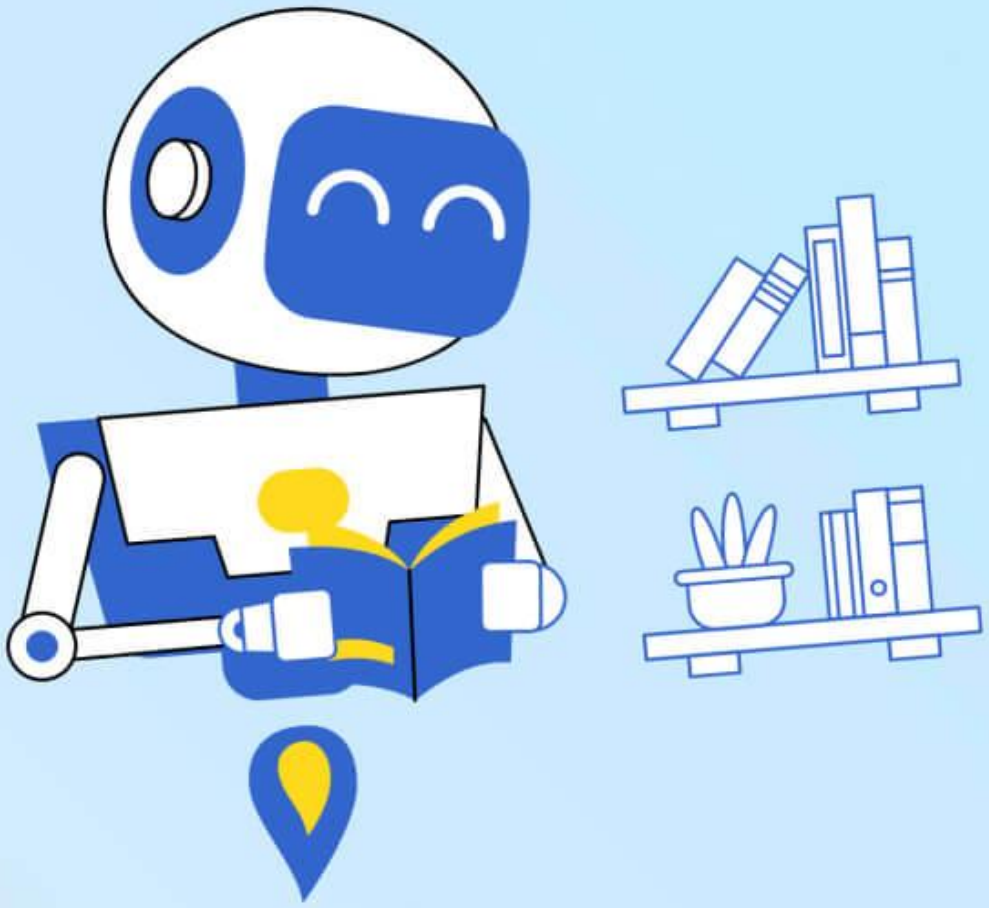

CHAPITRE 4 — Apprentissage non supervisé

1. Introduction et changement de paradigme.
2. Les trois branches de l'Apprentissage Non Supervisé.
3. Branche 1 : Clustering.
4. Branche 2 : Réduction de Dimensionnalité.
5. Branche 3 : Détection d'Anomalies.

Les trois branches de l'Apprentissage Non Supervisé.

Les Trois Branches Principales

1. **Clustering :** Rassembler des données similaires en groupes distincts.
2. **Réduction de Dimensionnalité :** Simplifier les données en réduisant le nombre de variables inutiles.
3. **Détection Anomalies :** Identifier les points de données rares ou suspects.

Les trois branches de l'Apprentissage Non Supervisé.

Comment choisir la bonne branche ?

Votre Objectif	Branche Recommandée	Algorithme Typique
Vous voulez segmenter ou grouper des items similaires.	Clustering	K-Means
Vous avez trop de variables et voulez simplifier ou visualiser.	Réduction de Dimensionnalité	PCA (Analyse en Composantes Principales)
Vous cherchez l'exception, l'erreur ou la fraude.	Détection d'Anomalies	Isolation Forest

Les trois branches de l'Apprentissage Non Supervisé.

Flux de Travail (Workflow) Typique

1. Collecte

Acquisition de données brutes (logs, images, capteurs).

2. Prétraitement/Traitement

Nettoyage, normalisation des données.

3. Analyse Non Supervisée

Clustering ou réduction pour comprendre la structure.

4. Action

Prise de décision ou étiquetage pour le supervisé.

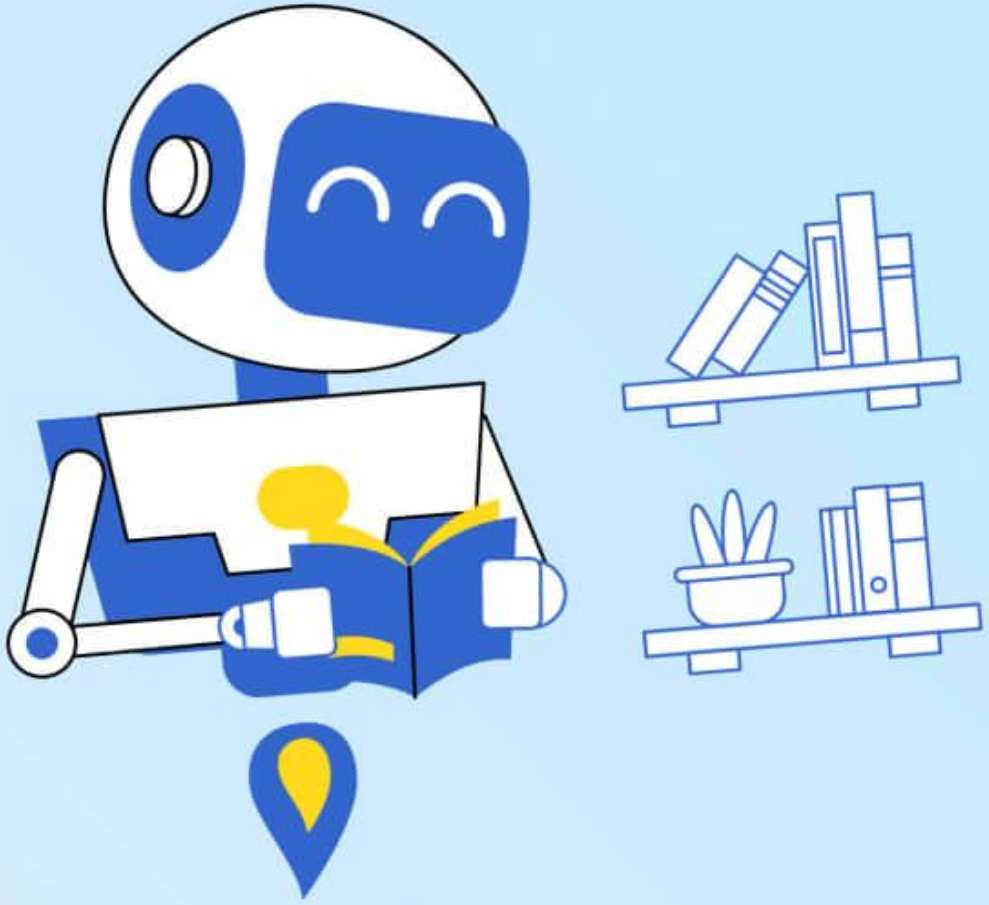

CHAPITRE 4 — Apprentissage non supervisé

1. Introduction et changement de paradigme.
2. Les trois branches de l'Apprentissage Non Supervisé.
3. Branche 1 : Clustering.
4. Branche 2 : Réduction de Dimensionnalité.
5. Branche 3 : Détection d'Anomalies.

Branche 1 :Clustering

Définition

Le clustering est une méthode d'apprentissage non supervisé qui regroupe automatiquement des données similaires en ensembles homogènes appelés clusters, sans étiquettes préalables. L'objectif est de maximiser la similarité intra-cluster et de minimiser la similarité inter-clusters, souvent via des mesures de distance comme l'euclidienne.

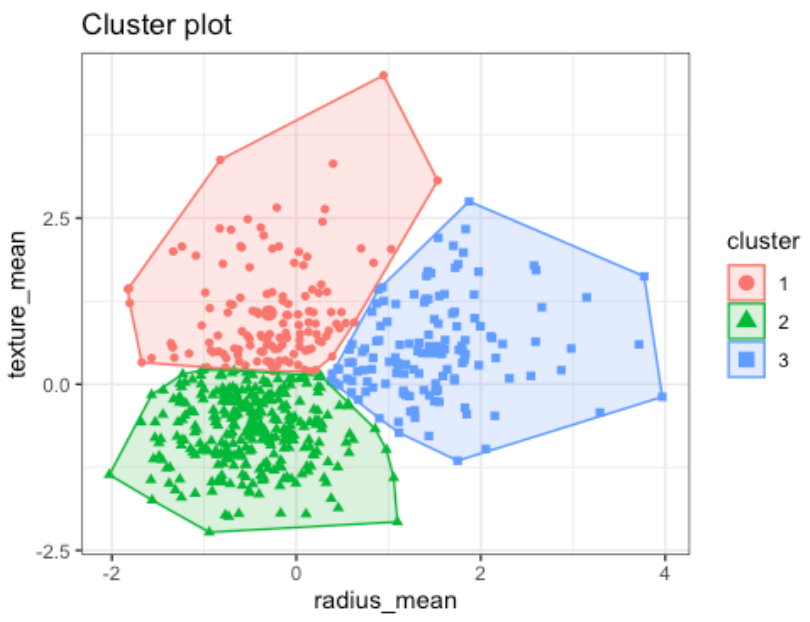

Cas d'Usage Pratiques

- Marketing : Segmentation de la clientèle par comportement.
- Santé : Regroupement de profils génétiques ou symptômes.

Algorithmes Clés

K-Means, DBSCAN, Classification ascendante hiérarchique (CAH).

Branche 1 :Clustering

Comparatif des Algorithmes

Algorithme	Définition & Fonctionnement	Particularité & Usage
K-Means	Partitionne les données en *k* clusters en minimisant la variance intra-classe (distance aux centroïdes).	Rapide et efficace sur grands datasets. Suppose des clusters sphériques de taille similaire.
CAH (Classification ascendante hiérarchique)	Construit une hiérarchie de clusters (dendrogramme) par des regroupements successifs.	Pas besoin de fixer *k* à l'avance. Idéal pour visualiser la structure des données (petits datasets).
DBSCAN	Base sur la densité : regroupe les points proches et marque les points isolés comme bruit.	Gère les formes arbitraires (non sphériques) et détecte les outliers (bruit). Paramètres : epsilon, min_samples.

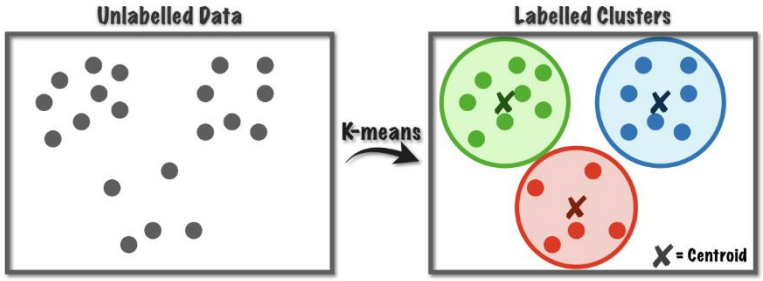

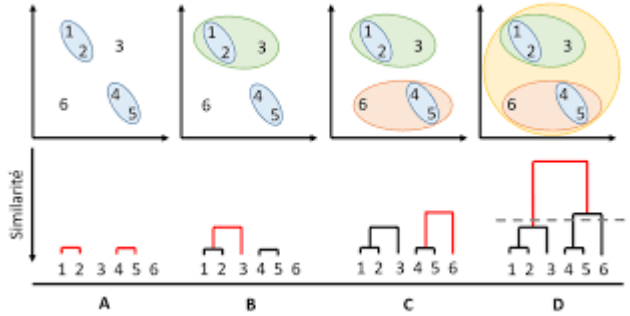

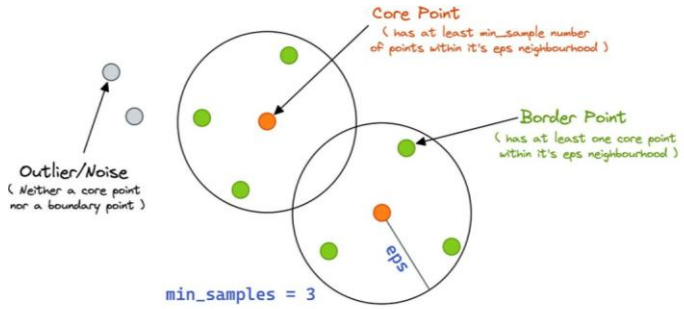

Branche 1 :Clustering

Métriques d'Évaluation

!! Les métriques guident, mais ne décident pas seules.

SCORE DE SILHOUETTE

Mesure à quel point un objet est similaire à son propre cluster, comparé aux autres clusters (séparation). Le score peut varier entre -1 et +1.

Interprétation :

- Un score proche de +1 : Clustering dense et bien séparé.
- Un score proche de 0 : Chevauchement de clusters.
- Un score proche de -1 : Mauvaise classification.

MÉTHODE DU COUDE (ELBOW)

Utilise l'inertie (somme des carrés des distances intra-cluster) pour déterminer le nombre optimal de clusters *k*.

Interprétation :

- On trace l'inertie en fonction de *k*.
- Le point d'inflexion (le "coude") indique le bon compromis entre compression et précision.

Branche 1 :Clustering

- Cas Pratique

CONTEXTE MARKETING

Une galerie marchande souhaite comprendre le comportement de ses clients pour adapter ses offres promotionnelles.

OBJECTIF

Segmenter la base de données clients en groupes distincts basés sur leurs habitudes d'achat et leurs revenus.

ALGORITHME

KMeans

LE DATASET

Source : Mall Customer Segmentation Data

CustomerID	Identifiant unique
Annual Income (k$)	Revenu annuel
Spending Score (1-100)	Score de dépense attribué par le magasin

Branche 1 :Clustering

- Cas Pratique

Distribution Initiale des Données

Avant d'appliquer un algorithme, il est crucial de visualiser la distribution des points.

Ici, nous traçons le Revenu Annuel (Axe X) contre le Score de Dépense (Axe Y). On peut déjà deviner visuellement des regroupements naturels.

Étapes du Projet :

1- Import & Nettoyage
2- Détermination de K (Elbow)
3- Modélisation (K-Means)
4- Analyse des Clusters

Branche 1 :Clustering

- Cas Pratique

Choix du Nombre de Clusters (K)

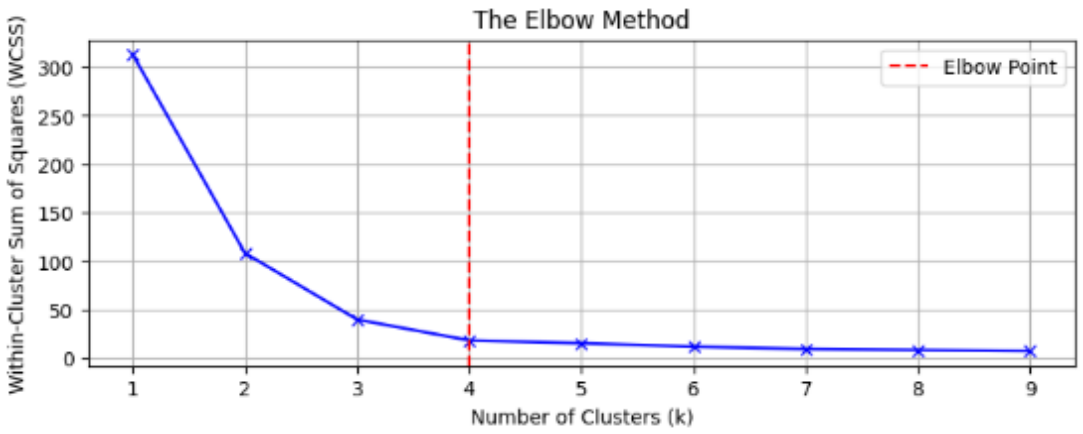

LA MÉTHODE DU COUDE

Nous entraînons l'algorithme K-Means pour *k* allant de 1 à 10 et calculons l'inertie (WCSS - Within-Cluster Sum of Squares).

```
wcss = []
for i in range(1, 11):
        kmeans = KMeans(n_clusters=i, init='k-means++',
        random_state=42)
        kmeans.fit(X)
        wcss.append(kmeans.inertia_)
```

Observation : La courbe forme un coude net à K = 5. C'est le nombre optimal de clusters pour ce dataset.

Branche 1 :Clustering

- Cas Pratique

1. PRÉTRAITEMENT & ENTRAÎNEMENT

Sélection des variables pertinentes et application du modèle avec K=5.

```
# Sélection des features (Income, Score)
X = dataset.iloc[:, [3, 4]].values
# Création du modèle K-Means
kmeans = KMeans(n_clusters=5, init='k-
means++', random_state=42)
# Prédiction des clusters
y_kmeans = kmeans.fit_predict(X)
```

2. VISUALISATION

Affichage des points colorés par cluster et des centroïdes.

```
# Visualisation des clusters
plt.scatter(X[y_kmeans == 0, 0], X[y_kmeans == 0, 1],
c='red', label='Cluster 1')
plt.scatter(X[y_kmeans == 1, 0], X[y_kmeans == 1, 1],
c='blue', label='Cluster 2')
# ... répéter pour clusters 3, 4, 5

# Affichage des centroïdes
plt.scatter(kmeans.cluster_centers_[:, 0],
kmeans.cluster_centers_[:, 1], s=300, c='yellow',
label='Centroids')
plt.show()
```

Branche 1 :Clustering

- Cas Pratique

Résultat Final : Segmentation

LÉGENDE

- Cluster 1 : Rouge
- Cluster 2 : Bleu
- Cluster 3 : Vert
- Cluster 4 : Marron
- Cluster 5 : Or

Branche 1 :Clustering

- Cas Pratique

Interprétation Stratégique

Cluster	Caractéristiques (Revenu / Dépense)	Nom du Segment	Action Marketing Recommandée
1	Revenu Élevé, Dépense Faible	"Économes"	Promotions de luxe, offres exclusives pour inciter à dépenser.
2	Revenu Moyen, Dépense Moyenne	"Standard"	Fidélisation classique, programmes de points.
3	Revenu Élevé, Dépense Élevée	"Cibles (VIP)"	Traitement VIP, avant-premières, maintien de la satisfaction.
4	Revenu Faible, Dépense Élevée	"Insouciants"	Coupons de réduction, offres "flash" (attention au risque crédit).
5	Revenu Faible, Dépense Faible	"Prudents"	Offres basiques, moins prioritaires pour les campagnes coûteuses.

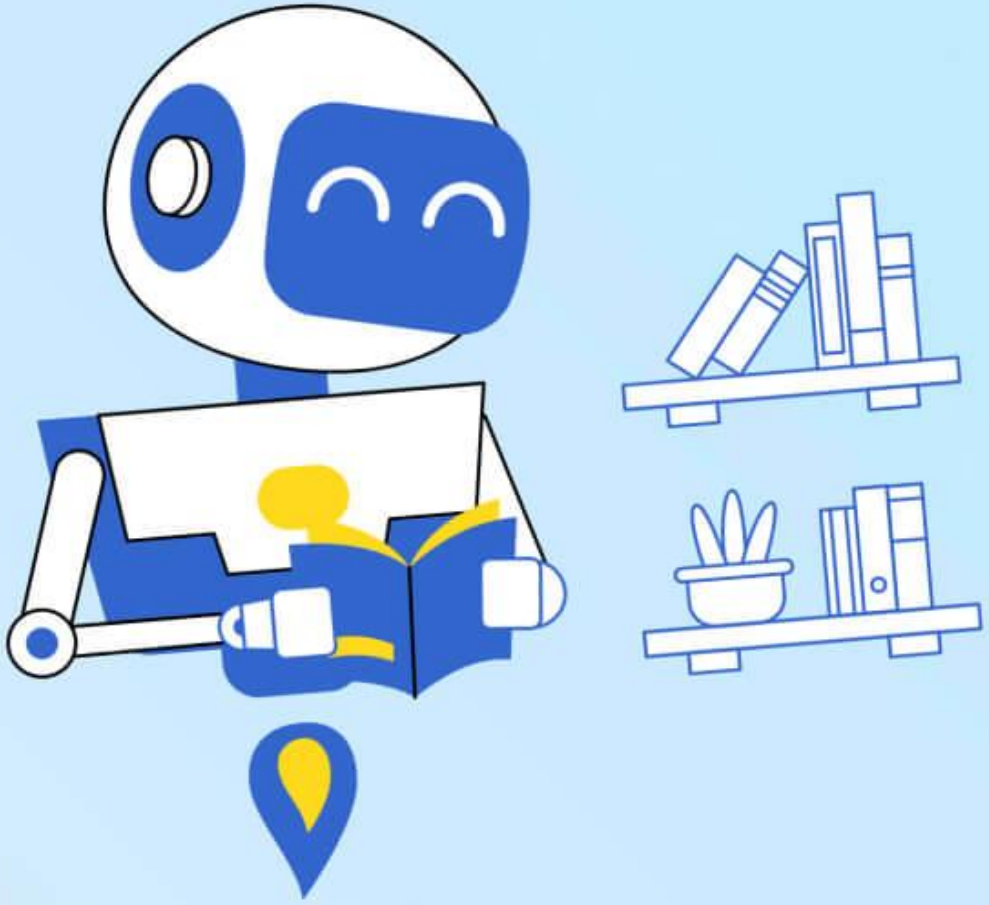

CHAPITRE 4 — Apprentissage non supervisé

1. Introduction et changement de paradigme.
2. Les trois branches de l'Apprentissage Non Supervisé.
3. Branche 1 : Clustering.
4. Branche 2 : Réduction de Dimensionnalité.
5. Branche 3 : Détection d'Anomalies.

Branche 2 : Réduction de Dimensionnalité

Définition

La réduction de dimensionnalité projette des données à haute dimension (fléau de la dimensionalité) vers un espace de faible dimension en conservant l'information essentielle. Elle combat la malédiction des dimensions, accélère les algorithmes et améliore la visualisation sans perte significative de variance.

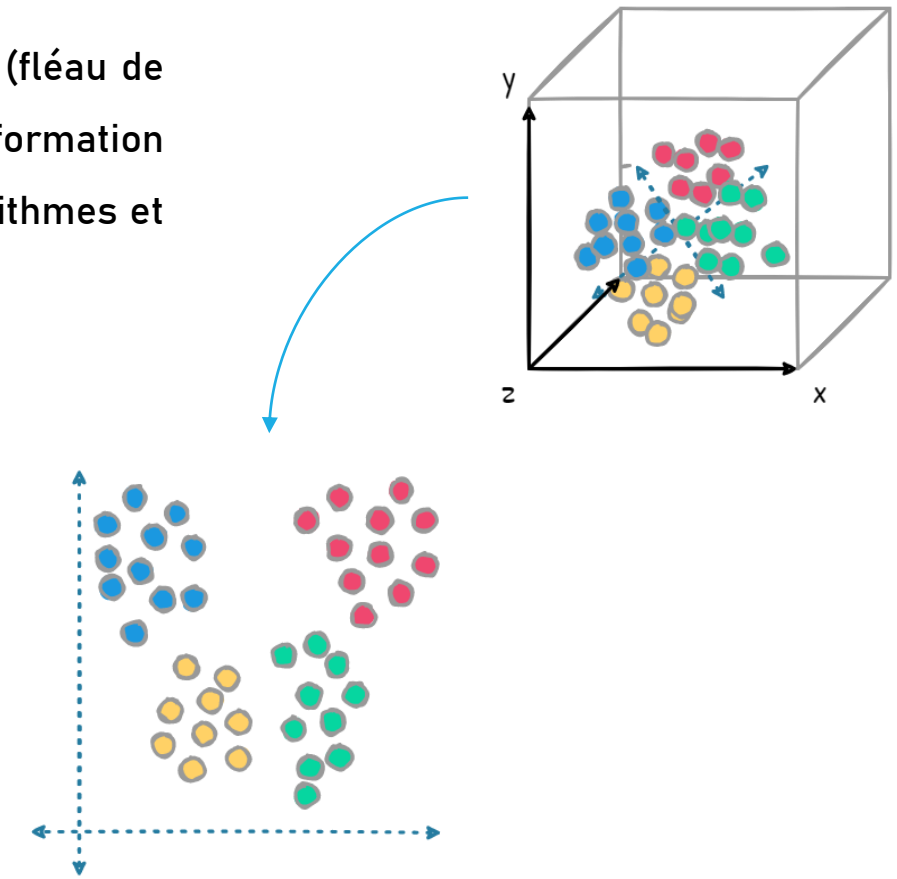

Cas d'Usage Pratiques

- Vision par ordinateur : Compression d'images.
- Génomique : Analyse de milliers de gènes.
- Visualisation : Passer de la 3D à la 2D.

Algorithmes Clés

PCA (Analyse en Composantes Principales), t-SNE, Autoencoders.

Branche 2 : Réduction de Dimensionnalité

Algorithmes Principaux

Le choix dépend de la linéarité des données et du besoin (visualisation vs compression).

Algorithme	Type	Particularité & Usage
ACP (PCA)	Linéaire	Maximise la variance. Rapide, idéal pour le pré-traitement et la compression simple.
t-SNE	Non-Linéaire	Conserve les voisinages locaux. Excellent pour la visualisation de clusters complexes.
UMAP	Non-Linéaire	Similaire à t-SNE mais plus rapide et préserve mieux la structure globale des données.
Auto-encodeurs	Réseau de Neurones	Compression puissante pour données très complexes (images, sons).

Branche 2 : Réduction de Dimensionnalité

- Analyse en Composantes Principales (ACP)

L'ACP est l'approche la plus classique. Elle cherche de nouveaux axes (composantes principales) qui capturent le maximum de variation dans les données.

- Principe : Rotation des axes pour aligner avec la plus grande variance.
- Avantage : Déterministe et peu coûteux en calcul.
- Limite : Ne capture que les relations linéaires.

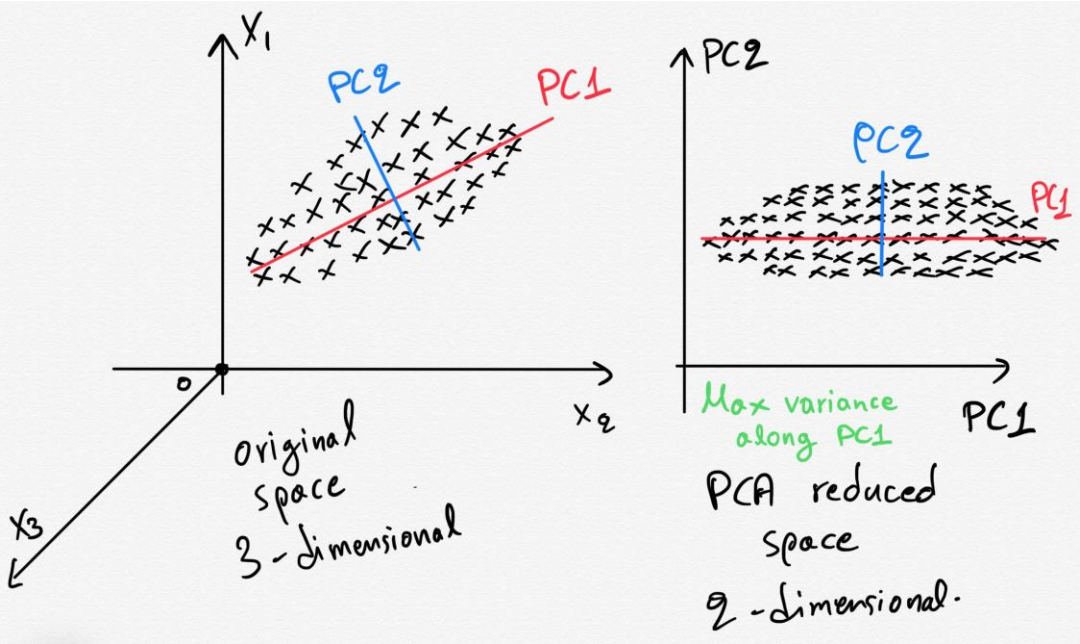

Branche 2 : Réduction de Dimensionnalité

- t-SNE (Non-Linéaire)

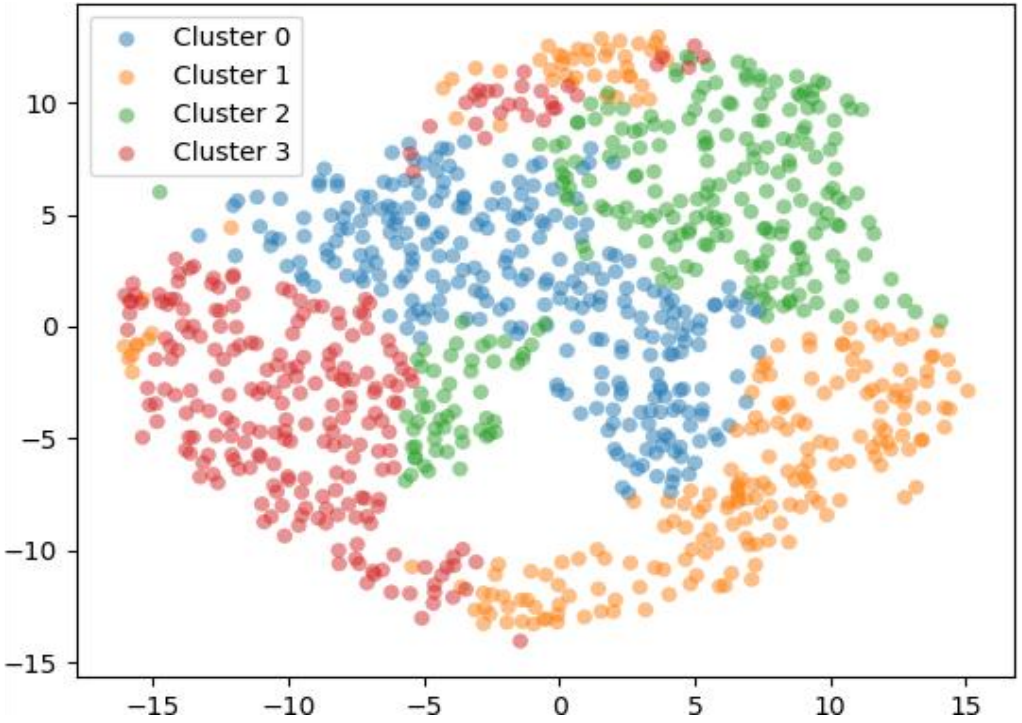

t-Distributed Stochastic Neighbor Embedding (t-SNE) est probabiliste.

- Principe : Convertit les similarités entre points en probabilités conjointes et tente de minimiser la divergence de Kullback-Leibler entre l'espace original et réduit.
- Force : Sépare visuellement des clusters que l'ACP empilerait les uns sur les autres.
- Usage : Exploration visuelle de données (ex: MNIST).

Branche 2 : Réduction de Dimensionnalité

- Cas Pratique

Problématique :

Dans un réseau "Smart Grid", des milliers de capteurs envoient des données chaque minute. Comment détecter des anomalies ou profiler des bâtiments sans étiquettes préexistantes ?

Solution :

Utiliser la réduction de dimensionnalité pour simplifier le signal avant le clustering.

Algorithme : PCA

Collection de Données & Dataset

Type de Collection : Séries temporelles via compteurs intelligents (Linky/IoT).

Dataset Choisi : "Individual Household Electric Power Consumption" (UCI Repository).

Feature (Variable)	Description
Global_active_power	Puissance active totale (kW)
Global_reactive_power	Puissance réactive totale (kW)
Voltage	Tension moyenne par minute (V)
Sub_metering_1/2/3	Consommation par zone (Cuisine, Buanderie, Clim)

Branche 2 : Réduction de Dimensionnalité

- Cas Pratique

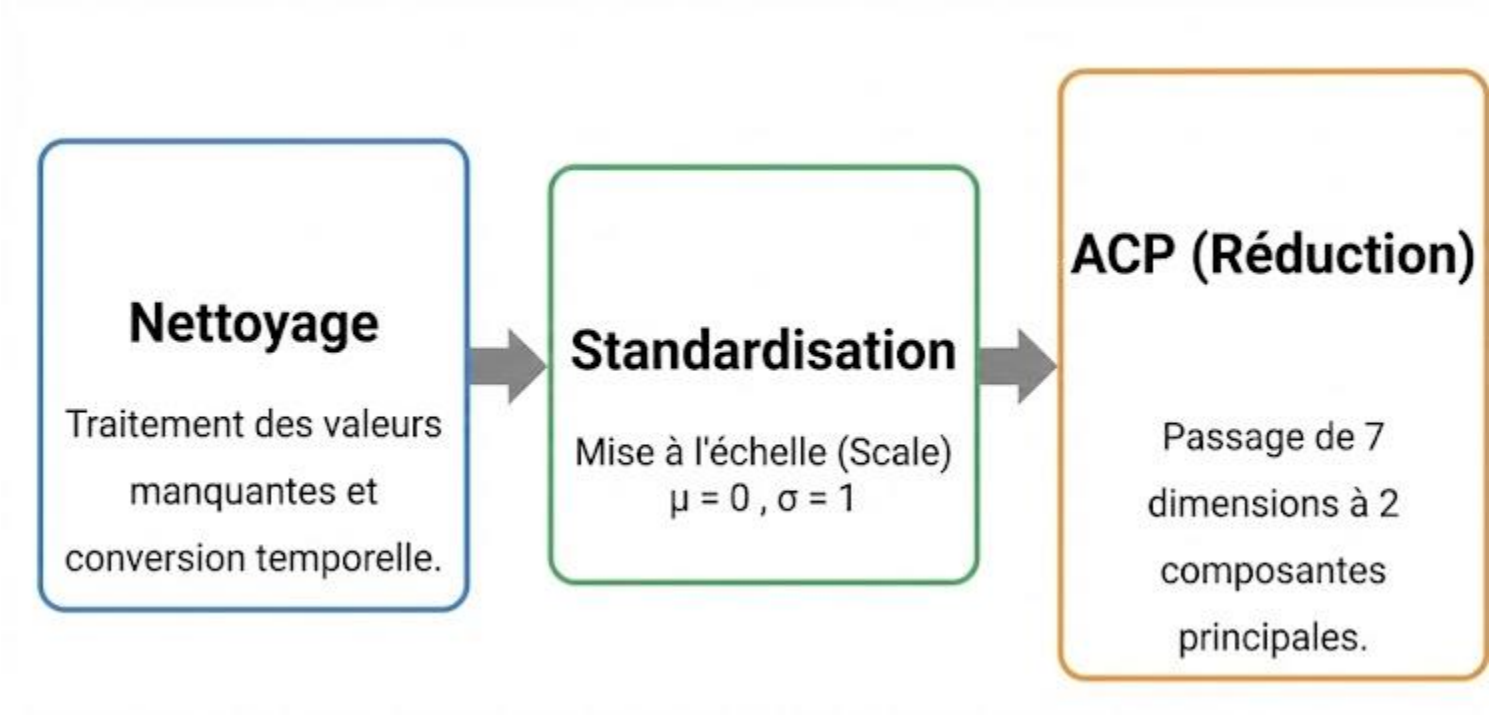

Branche 2 : Réduction de Dimensionnalité

- Cas Pratique

Code : Préparation & ACP

Utilisation de la librairie scikit-learn en Python.

La standardisation est cruciale pour l'ACP car elle est sensible aux échelles des variables (ex: Volts vs Kilowatts).

```
import pandas as pd
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

# 1. Chargement data
data = pd.read_csv('household_power.csv')
X = data[['Global_active_power', 'Voltage', ...]]

# 2. Standardisation (Essentiel)
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# 3. Application de l'ACP
# On garde 2 dimensions pour visualiser
pca = PCA(n_components=2)
X_reduced = pca.fit_transform(X_scaled)
```

Branche 2 : Réduction de Dimensionnalité

- Cas Pratique

```
print(f"Variance expliquée : {pca.explained_variance_ratio_}")
# Output: [0.65, 0.22] -> 87% de l'info conservée !

import matplotlib.pyplot as plt

plt.scatter(X_reduced[:,0], X_reduced[:,1], alpha=0.5)
plt.xlabel('Composante Principale 1 (Intensité)')
plt.ylabel('Composante Principale 2 (Voltage)')
plt.title('Projection de la Consommation')
plt.show()
```

Résultats & Interprétation

- Si la variance cumulée est élevée (>80%), la réduction est réussie.
- Sur le graphique, les points isolés sont des anomalies potentielles (pics de consommation, fuites).
- Les groupes denses représentent des comportements standards (nuit, jour, week-end).

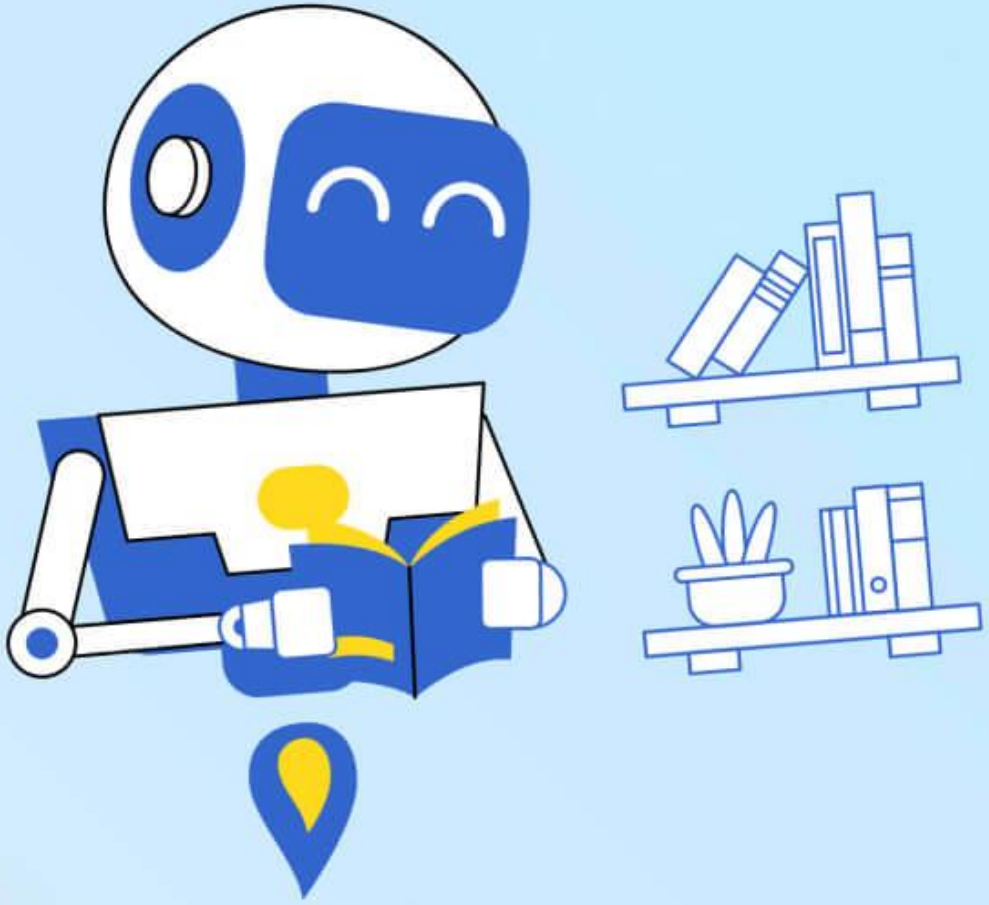

CHAPITRE 4 — Apprentissage non supervisé

1. Introduction et changement de paradigme.
2. Les trois branches de l'Apprentissage Non Supervisé.
3. Branche 1 : Clustering.
4. Branche 2 : Réduction de Dimensionnalité.
5. Branche 3 : Détection d'Anomalies.

Branche 3 : Détection d'Anomalies

Définition

La détection d'anomalies repère les points de données inhabituels qui s'éloignent beaucoup du comportement normal du reste des données.

Cas d'Usage Pratiques

- Cybersécurité : Intrusion réseau.
- Industrie : Maintenance prédictive (vibrations machines).
- Finance : Détection de fraude bancaire.

Algorithmes Clés

Isolation Forest, One-Class SVM, Local Outlier Factor (LOF).

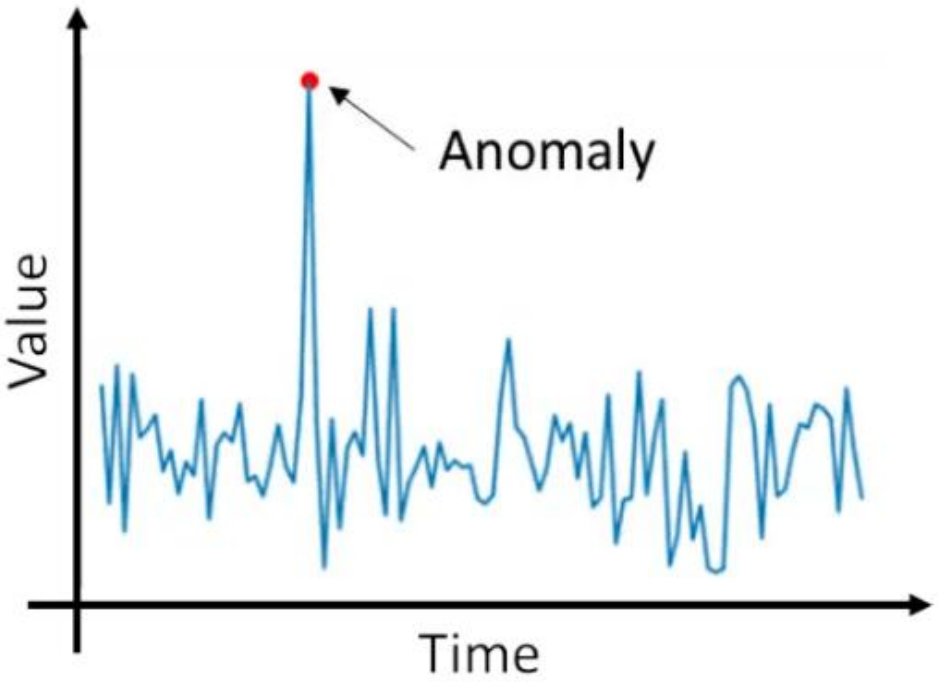

Branche 3 : Détection d'Anomalies

Mathématiquement, cet algorithme repose généralement sur l'estimation de densité (comme une Distribution Gaussienne Multivariée) ou sur des distances (comme la Distance de Mahalanobis). L'algorithme apprend d'abord les paramètres du "comportement normal" en calculant le vecteur moyen μ (le centre du nuage bleu) et la matrice de covariance Σ (qui décrit la forme et l'orientation de la dispersion bleue).

Pour un nouveau point de données x (un vecteur contenant les 3 valeurs des capteurs), l'algorithme calcule la probabilité p(x) que ce point appartienne à la distribution normale définie par :

$$p(x;\mu,\Sigma) = \frac{1}{(2\pi)^{\frac{k}{2}}|\Sigma \quad |^{\frac{1}{2}}} \exp(-\frac{1}{2}(x-\mu)^T \sum^{-1} (x-\mu)$$

Si cette probabilité p(x) est inférieure à un seuil défini epsilon, le système considère que la distance statistique par rapport au centre est trop grande.

$$y = \begin{cases} 1\ (\ Anomalie)\ si\ p(x) < \ \epsilon \\ \ 0\ (\ Normal\ )si\ p(x) \geq \varepsilon \end{cases}$$

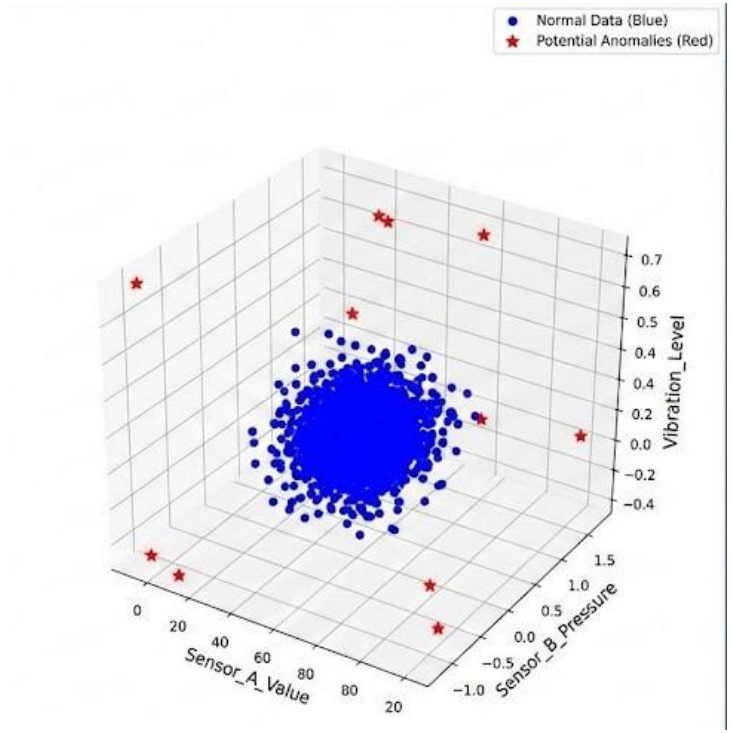

C'est ainsi que les points situés dans les régions de "faible densité" (les étoiles rouges) sont mathématiquement isolés et étiquetés comme anomalies.

Branche 3 : Détection d'Anomalies

Principaux Algorithmes

Voici les algorithmes les plus utilisés dans cette branche pour faciliter votre choix :

Algorithme	Définition Simplifiée	Particularité / Usage
Isolation Forest	Isole les anomalies en partitionnant aléatoirement les données (Arbres de décision).	Très efficace pour les données de haute dimension. Rapide.
Local Outlier Factor (LOF)	Compare la densité locale d'un point par rapport à ses voisins.	Efficace pour détecter des anomalies au sein de clusters denses.
One-Class SVM	Apprend une frontière stricte autour des données normales.	Idéal quand la forme des données normales est complexe/non-linéaire.
Autoencoders	Réseau de neurones qui tente de reconstruire l'entrée. L'erreur de reconstruction indique l'anomalie.	Puissant pour les données non structurées (images, séries temporelles complexes).

Branche 3 : Détection d'Anomalies

- Cas Pratique

1. La Problématique

Les sportifs et patients à risque portent des montres connectées. Nous voulons détecter automatiquement un comportement cardiaque anormal (arythmie, stress aigu) sans intervention humaine.

2. Les Données (Dataset)

Type : Séries Temporelles (Time Series).

Source : Capteurs (Fitbit, Apple Watch, ECG).

Features (Colonnes) :

- Timestamp (Temps)
- BPM (Battements par minute)
- HRV (Variabilité de la fréquence cardiaque)

Branche 3 : Détection d'Anomalies

- Cas Pratique

Flux de traitement pour transformer la donnée brute en alerte intelligente :

1. Collecte	2. Prétraitement	3. Modélisation	4. Décision
Extraction des logs CSV depuis le capteur.	Nettoyage et Normalisation (StandardScaler).	Entraînement de l'Isolation Forest.	Score d'anomalie > Seuil = Alerte.

Note Technique : L'apprentissage est non supervisé car nous n'avons pas besoin de labels "malade" à l'avance. Le modèle apprend ce qui est "normal" tout seul.

Branche 3 : Détection d'Anomalies

- Cas Pratique

Préparation des Données

Nous utilisons pandas pour manipuler les données et StandardScaler pour mettre les valeurs à la même échelle (essentiel pour les distances mathématiques).

- Chargement du CSV.
- Création de la trame de données.
- Normalisation des BPM.

Détection (Isolation Forest)

Nous initialisons l'algorithme avec un paramètre de contamination (estimation du % d'anomalies).

- fit(data) : Apprend la structure normale.
- predict(data) : Retourne -1 pour une anomalie, 1 pour normal.

Branche 3 : Détection d'Anomalies

- Cas Pratique

Visualisation des Résultats

Une fois le code exécuté, nous pouvons visualiser les points détectés sur la série temporelle.

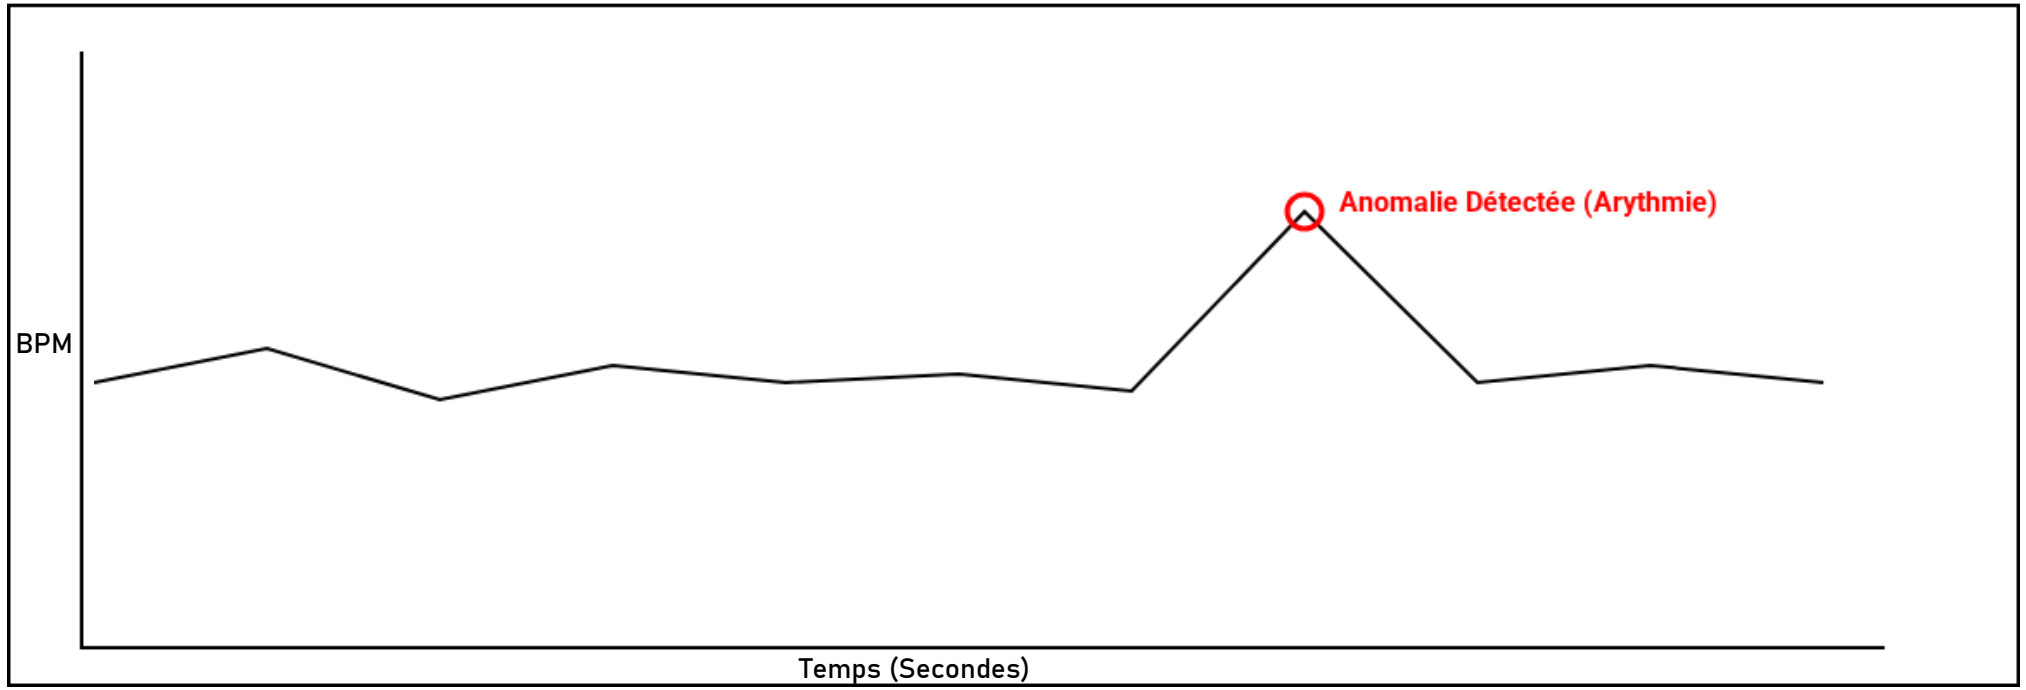

Erreurs Classiques en Apprentissage Non Supervisé

1- Absence de normalisation des données
Les algorithmes basés sur la distance (K-Means, PCA, LOF…) sont très sensibles aux échelles des variables.
> Une variable dominante peut fausser totalement les résultats.
2- Mauvais choix de distance ou de métrique
Distance euclidienne utilisée par défaut sans analyser la nature des données (angles, densité, corrélation).
> Similarité mal définie = clusters incohérents.
3- Choisir arbitrairement les hyperparamètres
Exemples : nombre de clusters *k*, seuil d'anomalie, contamination.
> Décisions subjectives sans validation statistique ou métier.
4- Sur-interprétation des résultats
Croire que chaque cluster correspond automatiquement à un profil réel ou exploitable.
> Un cluster ≠ une vérité métier.
5- Confondre visualisation et performance réelle
Un graphique "joli" (t-SNE) ne garantit pas une structure exploitable ou stable.